

Análisis de Calidad de Vinos Mediante Analítica de Datos Distribuida en Databricks

Javier Acuña y Rafael Rivera
Facultad de Ingeniería de Sistemas Computacionales
Universidad Tecnológica de Panamá
Ciudad de Panamá, Panamá
javier.acuna@utp.ac.pa, rafael.rivera2@utp.ac.pa

RESUMEN (Abstract)

Este artículo presenta un análisis de datos de extremo a extremo sobre el conjunto de datos Wine Quality del UCI Machine Learning Repository, implementado en la plataforma Databricks Free Edition. El pipeline cubre ingesta de datos, limpieza, análisis exploratorio, consultas SQL y un modelo de clasificación Random Forest para predecir si un vino es de calidad alta. El dataset contiene 6,497 muestras de vinos portugueses tintos y blancos, descritos por once atributos fisicoquímicos. El modelo obtuvo una exactitud de 84.6%, un AUC-ROC de 0.846 y un F1-Score de 0.827. Los resultados indican que el contenido de alcohol, la acidez volátil y los sulfatos son los factores más influyentes en la calidad percibida del vino.

Palabras clave: analítica de datos, calidad de vino, Databricks, Random Forest, PySpark, aprendizaje automático, Delta Lake.

I. INTRODUCCIÓN

La evaluación de la calidad del vino ha dependido tradicionalmente de catadores humanos, un proceso subjetivo, costoso y difícil de escalar. Cortez et al. [1] demostraron que modelos de aprendizaje automático entrenados sobre propiedades fisicoquímicas pueden predecir la calidad con precisión comparable a la evaluación sensorial. En este contexto, plataformas como Databricks unifican SQL, Python y aprendizaje automático en un entorno escalable y reproducible [2], facilitando pipelines analíticos completos sin infraestructura propia.

Este proyecto aplica dicho enfoque sobre el Wine Quality Dataset [1] para identificar los atributos químicos que más influyen en la calidad del vino y presentar los hallazgos mediante un dashboard interactivo accesible para tomadores de decisiones no técnicos, usando Apache Spark MLlib [3] para el componente predictivo.

Para el análisis se categorizó la calidad en tres niveles: Alta (≥ 7), Media (5–6) y Baja (< 5), siguiendo el criterio utilizado en la literatura de referencia [1].

B. Pipeline de análisis

El análisis fue implementado en seis notebooks dentro de Databricks Free Edition. Los datos fueron descargados directamente desde UCI usando pandas y almacenados como tabla Delta persistente en Apache Spark [3]. La etapa de limpieza eliminó 1,177 registros duplicados y añadió la columna derivada `quality_category`. El análisis exploratorio examinó distribuciones, correlaciones y perfiles químicos por categoría. Las consultas SQL generaron vistas agregadas para el dashboard. Finalmente, se entrenó un clasificador Random Forest [4] mediante Spark MLlib [3] con división 80/20, 100 árboles y semilla fija para reproducibilidad.

II. CONJUNTO DE DATOS Y METODOLOGÍA

A. Conjunto de datos

El Wine Quality Dataset [1] contiene 1,599 muestras de vino tinto y 4,898 de vino blanco, para un total de 6,497 registros de vinos portugueses de la variedad Vinho Verde. Cada muestra está descrita por once variables fisicoquímicas continuas: acidez fija, acidez volátil, ácido cítrico, azúcar residual, cloruros, dióxido de azufre libre, dióxido de azufre total, densidad, pH, sulfatos y contenido de alcohol. La variable objetivo es una puntuación de calidad entre 0 y 10 asignada por enólogos certificados.

III. RESULTADOS Y ANÁLISIS

A. Análisis exploratorio

El análisis exploratorio reveló que el 75.4% de las muestras corresponde a vino blanco, mientras que el 18.9% de los vinos totales alcanza la categoría de calidad Alta. El contenido de alcohol presentó la correlación positiva más fuerte con la calidad ($r = 0.469$), mientras que la acidez volátil mostró la correlación negativa más pronunciada ($r = -0.265$), resultado consistente con los hallazgos de Cortez et al. [1]. El perfil químico por categoría, visible en el dashboard (Fig. 1), confirma que los vinos de

calidad Alta presentan sistemáticamente mayor alcohol y menor acidez volátil, tanto en vinos tintos como blancos.

B. Modelo predictivo

El clasificador Random Forest [4] alcanzó los resultados presentados en la Tabla I. El análisis de importancia de características (Fig. 2) identificó al alcohol, la acidez volátil y los sulfatos como las tres variables más determinantes, en concordancia con el análisis de correlaciones. Como se observa en la Fig. 3, el modelo presenta mayor precisión en la clase Media, atribuible al desbalance de clases inherente al dataset, donde los vinos de calidad Alta representan una minoría de las muestras.

IV. CONCLUSIONES

Este proyecto demostró la viabilidad de Databricks como plataforma integrada para análisis de datos de extremo a extremo, desde la ingesta hasta el aprendizaje automático y la visualización interactiva. El modelo Random Forest clasificó correctamente la calidad del vino con una exactitud de 84.6%, confirmando que el alcohol y la acidez volátil son predictores robustos de la calidad percibida. El dashboard desarrollado proporciona una herramienta práctica para explorar patrones de calidad de forma interactiva. Como trabajo futuro, se propone abordar el desbalance de clases con técnicas de sobremuestreo como SMOTE.

REFERENCIAS

[1] P. Cortez, A. Cerdeira, F. Almeida, T. Matos, y J. Reis, "Modeling wine preferences by data mining from physicochemical properties," *Decision Support Systems*, vol. 47, no. 4, pp. 547–553, Nov. 2009, doi: 10.1016/j.dss.2009.05.016.

[2] Databricks, "Databricks Free Edition," Databricks, Inc., 2025. [En línea]. Disponible en: <https://www.databricks.com/learn/free-edition>. [Accedido: jul. 2025].

[3] X. Meng *et al.*, "MLlib: Machine learning in Apache Spark," *Journal of Machine Learning Research*, vol. 17, no. 34, pp. 1–7, 2016.

[4] L. Breiman, "Random Forests," *Machine Learning*, vol. 45, no. 1, pp. 5–32, Oct. 2001, doi: 10.1023/A:1010933404324.

TABLA I — Métricas de evaluación del modelo Random Forest

Métrica	Valor
Accuracy	84.57%
AUC-ROC	0.8463

F1-Score	0.8270
Train/Test	80 / 20
Núm. árboles	100

Tabla I. Resultados del clasificador Random Forest sobre el conjunto de prueba.

FIGURAS



Fig. 1 — Dashboard interactivo de calidad de vinos en Databricks




Fig. 2 —Importancia de características del modelo Random Forest.




Fig. 3 — Comparación entre predicciones del modelo y calidad real por puntuación.